

Day5 作業報告：三種切塊方法之 RAG 檢索效果比較

2026_2504 次世代 DocAI 系統工作坊 | 學號：2411332043 | 姓名：黃皓德

一、實驗設定

本次作業以 data_01.txt ~ data_05.txt 共 5 份文件作為知識庫，針對 questions.csv 中的 20 個問題，分別以三種切塊方法建立索引並進行檢索，每題取回相似度最高的 1 個文字塊，共產生 $20 \times 3 = 60$ 筆結果。

向量模型使用 Google gemini-embedding-001（維度 768），檢索方式為餘弦相似度（Cosine Similarity）。

二、問題一：固定大小切塊與滑動視窗切塊的參數設定

三種切塊方法的參數設定如下表。其中固定大小與滑動視窗的差別在於「是否重疊」：滑動視窗以 250 字為步長前進，因此相鄰兩塊會有 250 字（50%）的重疊，目的是避免答案剛好被切斷在兩塊交界處。

切塊方法	參數設定	實際產生塊數
固定大小	chunk_size = 500 字, overlap = 0（不重疊）	40 塊
滑動視窗	window_size = 500 字, step = 250 字（重疊 250 字, 重疊率 50%）	71 塊
語意切塊	以句子為單位, 相鄰句餘弦相似度低於第 25 百分位處切開, 單塊上限 800 字	87 塊

設定理由：500 字約可容納一個完整段落的語意，過小容易切斷語句、過大則會稀釋向量的語意焦點；重疊率設為 50% 是常見的折衷，能明顯降低邊界斷句的風險，代價是索引量約增加一倍。

三、問題二：哪一種切塊方法效果最好？

評分方式：將每一題檢索到的文字塊與問題一併送入 LLM

評審（Gemini），依「該段落是否包含足以回答問題的資訊」給予 0 ~ 1 分，再取每種方法 20 題的平均值。

排名	切塊方法	平均分數	滿分(1.0)題數	低分(<0.5)題數
1	滑動視窗	0.9050	15 / 20	1 / 20
2	固定大小	0.8500	13 / 20	2 / 20
3	語意切塊	0.8500	13 / 20	2 / 20

結論：平均分數最高的切塊方法為「滑動視窗」，平均分數 0.9050。

四、結果分析

三種方法的平均分數分別為：滑動視窗 0.9050、固定大小 0.8500、語意切塊 0.8500，最高與最低相差 0.0550。

各方法的特性觀察：

- 固定大小切塊：實作最簡單、索引量最小，但切點是機械式的字數切分，若答案剛好橫跨兩塊交界，就會導致檢索到的段落資訊不完整。
- 滑動視窗切塊：以重疊換取邊界的容錯能力，同一段內容會出現在多個塊中，因此答案被切斷的機率大幅降低；缺點是索引量約為固定大小的兩倍，成本與檢索時間增加。
- 語意切塊：依相鄰句子的向量相似度找出語意轉折點才切塊，每一塊在語意上最完整、雜訊最少；但需要額外對每個句子做 embedding，前置成本最高，且切塊品質會受句子切分規則與相似度門檻的影響。

五、逐題檢索分數明細

下表列出 20 題在三種切塊方法下的檢索分數與命中來源檔案。

題號	固定大小	滑動視窗	語意切塊
1	1.00 data_02.txt	1.00 data_02.txt	1.00 data_02.txt
2	0.80 data_03.txt	0.80 data_03.txt	0.90 data_03.txt
3	1.00 data_01.txt	1.00 data_01.txt	1.00 data_01.txt
4	1.00 data_01.txt	1.00 data_01.txt	1.00 data_01.txt
5	0.80 data_05.txt	0.80 data_05.txt	0.80 data_05.txt
6	0.20 data_05.txt	0.00 data_05.txt	1.00 data_05.txt
7	1.00 data_01.txt	0.80 data_01.txt	1.00 data_01.txt
8	1.00 data_04.txt	1.00 data_04.txt	1.00 data_04.txt
9	1.00 data_02.txt	1.00 data_02.txt	0.70 data_02.txt
10	0.40 data_03.txt	1.00 data_03.txt	1.00 data_03.txt
11	0.50 data_01.txt	1.00 data_01.txt	0.20 data_01.txt
12	0.50 data_02.txt	1.00 data_02.txt	1.00 data_02.txt
13	1.00 data_04.txt	1.00 data_04.txt	0.50 data_04.txt
14	1.00 data_02.txt	1.00 data_02.txt	0.40 data_02.txt
15	1.00 data_03.txt	1.00 data_03.txt	1.00 data_03.txt
16	0.80 data_05.txt	0.70 data_05.txt	1.00 data_05.txt
17	1.00 data_03.txt	1.00 data_03.txt	1.00 data_03.txt
18	1.00 data_04.txt	1.00 data_04.txt	1.00 data_04.txt

題號	固定大小	滑動視窗	語意切塊
19	1.00 data_04.txt	1.00 data_04.txt	1.00 data_04.txt
20	1.00 data_02.txt	1.00 data_02.txt	0.50 data_05.txt
平均	0.8500	0.9050	0.8500

六、附註

課程原提供的評分 API (ws-02.wade0426.me) 已於課程結束後關閉，因此本作業改以 Gemini LLM 作為評審模型 (LLM-as-a-Judge) 取得分數，評分函數為程式中的 `get_score()`，評分標準已固定於 prompt 中並設定 `temperature = 0` 以確保可重現性。

完整程式碼見 2411332043_RAG_HW_01.py，完整結果見 2411332043_RAG_HW_01.csv (60 筆，utf-8-sig 編碼)。