

Day6 作業報告：以 DeepEval 指標驅動 RAG 客服系統優化

2026_2504 次世代 DocAI 系統工作坊 | 學號：2411332043 | 姓名：黃皓德

一、系統架構

本系統以台灣自來水公司的公開客服問答資料（qa_data.txt）為知識庫，建立 AI 客服助手。原始資料為多組「問題／發布日期／答案／來源網址」，因此切塊時以一組完整問答為一個 chunk，而非固定字數硬切，讓每個檢索單位在語意上都是完整的。

階段	技術	作法
1	Query Rewrite	以 LLM 將口語化問題改寫為正式檢索語句，補上專業術語
2	Hybrid Search	BM25 關鍵字檢索 + 向量語意檢索，以 RRF (k=60) 融合兩路排名，各取前 10 名
3	Rerank	以 LLM 對 10 筆候選逐一評分 (0~10) 後重新排序，保留前 3 名
4	LLM 生成	將前 3 名段落作為上下文，要求模型僅依參考資料作答

二、DeepEval 五項指標：各自診斷什麼問題

DeepEval 的價值不只在於「打一個分數」，而是每個指標會指向 RAG 流程中不同的失效環節。以下說明每個指標量測的內容、分數偏低代表的問題，以及本系統據此採取的對應優化。

Faithfulness（忠實度）

- 量測內容：回答中的每一項陳述，是否都能在檢索到的上下文中找到依據。
- 診斷意義：分數低代表 LLM 產生了幻覺（憑空捏造上下文沒有的內容）。
- 對應優化：在 Answer Prompt 中明確要求「僅能使用參考資料作答，資料不足時須明說查無資訊」，並將 temperature 設為 0 降低發散。

Answer_Relevancy（答案相關性）

- 量測內容：回答是否切題，有沒有答非所問或塞入大量無關內容。
- 診斷意義：分數低代表回答離題、或加了太多與問題無關的贅述。
- 對應優化：在 Prompt 中限制回答長度（150 字內）、要求直接作答不要開場白，使回答聚焦於使用者真正問的事。

Contextual_Recall（上下文召回率）

- 量測內容：標準答案中的資訊，有多少比例能在檢索到的上下文中被找到。
- 診斷意義：分數低代表「檢索漏掉了關鍵資料」——正確答案根本沒被撈進來，後面再強的 LLM 也救不回。

- 對應優化：導入 Query Rewrite（把口語問題改寫成正式檢索詞）與 Hybrid Search（BM25 補足向量檢索對專有名詞不敏感的弱點），提高關鍵段落被撈到的機率。

Contextual_Precision（上下文精確度）

- 量測內容：真正有用的段落，是否被排在檢索結果的前面。
- 診斷意義：分數低代表雖然撈到了正確資料，但排序不佳，有用的段落被雜訊擠到後面。
- 對應優化：加入 Rerank 階段，以 LLM 對候選段落逐一評分後重新排序，只取前 3 名送進生成階段。

Contextual_Relevancy（上下文相關性）

- 量測內容：檢索到的上下文中，與問題相關的內容佔多少比例。
- 診斷意義：分數低代表上下文夾帶太多不相關的雜訊，會干擾 LLM 生成。
- 對應優化：以「一組完整問答」為切塊單位（而非固定字數硬切），並將送入 LLM 的段落數由 10 收斂到 Rerank 後的前 3 名。

三、優化成效：基線 vs 優化版

為驗證上述優化確實有效，另外實作一套未優化的基線系統（僅純向量檢索取前 3 名，不做 Query Rewrite、不做 Hybrid Search、不做 Rerank），在相同的 10 道題目與相同的五項指標下進行對照。

指標	基線	優化版	提升
Faithfulness 忠實度	1.0000	0.9833	-0.0167
Answer_Relevancy 答案相關性	0.9633	0.9800	+0.0167
Contextual_Recall 上下文召回率	0.8334	0.8500	+0.0166
Contextual_Precision 上下文精確度	0.9249	0.9583	+0.0334
Contextual_Relevancy 上下文相關性	0.5023	0.5552	+0.0529

五項指標中有 4 項上升，提升幅度最大的是

Contextual_Relevancy（上下文相關性）+0.0529。這兩項（上下文精確度與上下文相關性）正是 Rerank 直接作用的環節：把 Hybrid Search 撈回的 10 筆候選重新排序後只留前 3 名，等於同時提高了「有用段落排在前面」的比例，也降低了送進 LLM 的雜訊量。

另一方面，Faithfulness（忠實度）略為下降。這是可以理解的取捨：基線系統只拿到 3 段純向量檢索的內容，可講的東西少、幾乎照抄原文，因此忠實度容易滿分；優化版檢索到更豐富且更相關的上下文後，模型會做較多整合與改寫，些微增加了偏離原文的風險。以客服場景而言，用 0.0167 的忠實度換取檢索品質與答案相關性的提升是值得的，且忠實度仍維持在 0.9833 的高水準。

四、優化版系統在全部題目上的最終成績

指標	平均分數	通過門檻(0.7)題數
Faithfulness 忠實度	0.9778	29 / 30
Answer_Relevancy 答案相關性	0.9656	28 / 30
Contextual_Recall 上下文召回率	0.8084	20 / 30
Contextual_Precision 上下文精確度	0.9861	29 / 30
Contextual_Relevancy 上下文相關性	0.5074	7 / 30

全部 30 題的詳細答案與逐題分數，請見 day6_HW_questions.csv。

五、觀察與後續改進方向

目前分數最低的指標為 Contextual_Relevancy（上下文相關性）（0.5074），依前述診斷邏輯，這代表：分數低代表上下文夾帶太多不相關的雜訊，會干擾 LLM 生成。

後續可嘗試的改進方向：（1）Query Rewrite

改為產生多個查詢變體（Multi-Query）再合併結果，進一步提高召回率；（2）改用專門的 Cross-Encoder 重排序模型取代 LLM Rerank，降低成本與延遲；（3）針對分數偏低的題目做錯誤分析，判斷是知識庫本身缺資料，還是檢索或生成環節的問題。

評估模型：Gemini（temperature = 0）；評估框架：DeepEval。程式碼見 day6_HW.py（主系統）與 day6_ablation.py（基線對照實驗）。